

FACULTAD DE CIENCIAS
GRADO EN MATEMÁTICAS
TRABAJO FIN DE GRADO
CURSO ACADÉMICO 2025-2026

TÍTULO:

MÁQUINAS DE VECTORES DE SOPORTE (SVM)

AUTOR:

DANIEL SÁNCHEZ BOTELLA

Resumen

Este Trabajo de Fin de Grado presenta un estudio detallado de las Máquinas de Vectores de Soporte (SVM), uno de los algoritmos más robustos y eficaces del aprendizaje automático supervisado. El objetivo principal de la memoria es indagar en los fundamentos matemáticos de esta técnica y evaluar su rendimiento frente a diversos escenarios reales.

En primer lugar, se desarrolla el marco teórico del modelo, comenzando por la definición geométrica de los hiperplanos discriminantes y los clasificadores de máximo margen. Posteriormente, se analiza la suavización de estas fronteras y la proyección de los datos a espacios de mayor dimensión por medio de funciones kernel. Asimismo, el estudio abarca la adaptación del algoritmo original a la clasificación multiclase y a la predicción de variables continuas mediante la Regresión de Vectores de Soporte (SVR).

En la fase práctica, se aplican los conceptos teóricos utilizando el lenguaje de programación R con el paquete `e1071`. Para ello, se evalúa y compara el comportamiento de los kernels lineal, polinómico y radial sobre tres conjuntos de datos reales: diagnóstico de tumores mamarios (clasificación binaria), identificación de siluetas de vehículos (clasificación multiclase) y estimación de la edad biológica en moluscos (regresión).

Los resultados obtenidos demuestran la gran capacidad predictiva y la versatilidad de este método. Las SVM logran construir fronteras de decisión precisas y estables dependiendo tan solo de una pequeña fracción de los datos originales, los vectores de soporte, confirmando así su eficiencia computacional y su resistencia frente al sobreajuste.

Palabras clave: Máquinas de Vectores de Soporte (SVM), aprendizaje automático, clasificación, funciones kernel, Regresión de Vectores de Soporte (SVR)

Abstract

This Final Degree Project presents a detailed study of Support Vector Machines (SVM), one of the most robust and efficient supervised machine learning algorithms. The main objective of the thesis is to investigate the mathematical basis of this technique and to evaluate its practical performance against diverse real scenarios.

Firstly, the theoretical framework of the model is developed, beginning with the geometrical definition of discriminating hyperplanes and maximal margin classifiers. Then, the softening of these boundaries and the projection of the data to higher-dimensional spaces by kernel functions are analysed. In addition, the study covers the adaptation of the original algorithm into multiclass classification and the prediction of continuous variables through Support Vector Regression (SVR).

In the practical phase, the theoretical concepts are applied using the programming language R with the `e1071` package. For that purpose, the behaviour of linear, polynomial and radial kernels is evaluated and compared over three real datasets: breast tumour diagnosis (binary classification), vehicle silhouettes identification (multiclass classification) and estimation of the biological age in molluscs (regression).

The results obtained show the great predictive ability and the versatility of this method. SVM manage to build accurate and stable decision boundaries depending only on a small fraction of the original data, the support vectors, thus confirming their computational efficiency and robustness against overfitting.

Keywords: Support Vector Machines (SVM), machine learning, classification, kernel functions, Support Vector Regression (SVR)

Índice

1. Introducción	6
2. Fundamentos teóricos de las Máquinas de Vectores de Soporte	8
2.1. Hiperplanos discriminantes	8
2.2. Clasificadores de máximo margen	10
2.2.1. Vectores de Soporte	11
2.2.2. El caso no separable	13
2.3. Clasificadores de vectores de soporte	14
2.3.1. Formulación dual y condiciones de optimalidad	16
2.4. Máquinas de Vectores de Soporte	20
2.4.1. Tipos de kernel	21
2.5. El enfoque de penalización y la función Hinge Loss	23
2.6. Clasificación multiclase	26
2.7. Máquinas de Vectores de Soporte para Regresión (SVR)	27
3. Aplicación práctica de SVM en R	34
3.1. Metodología y software a utilizar	34
3.1.1. Metodología de evaluación	34
3.1.2. Métricas de rendimiento	35
3.1.3. Herramientas de software	37
3.2. Caso Práctico I: Clasificación binaria	38
3.3. Caso Práctico II: Clasificación multiclase	41
3.4. Caso Práctico III: Regresión	43
4. Conclusiones	47
Referencias	48
A. Código utilizado en R y Resultados Complementarios	50
A.1. Caso Práctico I: Clasificación Binaria	50

A.2. Caso Práctico II: Clasificación Multiclase	52
A.3. Caso Práctico III: Regresión	54
B. Detalles del desarrollo del trabajo	57

1. Introducción

Aunque sus fundamentos teóricos fueron asentados por Vapnik y Chervonenkis en 1964 [15], la popularización de las Máquinas de Vectores de Soporte comienza en la década de 1990. En aquel periodo, los modelos predictivos se basaban principalmente en los métodos lineales clásicos. Al desarrollarse ordenadores más potentes, cada vez se utilizaban métodos más complejos como las redes neuronales para identificar patrones no lineales. Sin embargo, estos algoritmos presentaban numerosos problemas: aprendían mediante un proceso de ensayo y error y en ocasiones se atascaban en mínimos locales, sin gozar de una teoría sólida en la que apoyarse [5].

La revolución de las SVM se dio en 1992 cuando Vapnik, Boser y Guyon introdujeron el *truco del kernel* para trabajar adecuadamente con datos no lineales [2]. En 1995, Cortes y Vapnik publicaron la versión definitiva del algoritmo incluyendo el concepto de margen suave [4]. Este fue un gran logro para la época, ya que las SVM contaban con la gran base de la Teoría del Aprendizaje Estadístico [16] y siempre garantizaban encontrar la solución óptima, a diferencia de las redes neuronales.

Originalmente, las Máquinas de Vectores de Soporte estaban pensadas para resolver problemas de clasificación binaria, con la principal tarea de determinar la frontera que maximizase el espacio entre los individuos de distintas clases. Su capacidad para manejar datos no lineales mediante funciones kernel las convirtieron en el algoritmo más eficiente del momento, pues mostraban un rendimiento nunca visto sobre conjuntos de datos complejos como el reconocimiento de caracteres manuscritos o el procesamiento de textos [4, 7]. A día de hoy, las SVM se emplean tanto en clasificación (ya sea binaria o respecto a varias categorías) como en regresión.

La motivación de este Trabajo de Fin de Grado es, entonces, ahondar en el trasfondo matemático de este algoritmo, así como poner a prueba su rendimiento resolviendo problemas reales mediante software estadístico. Concretamente, la memoria está estructurada de la siguiente manera:

- En la Sección 2, exploraremos los fundamentos teóricos de las SVM, desde los clasificadores de máximo margen hasta los tipos de kernel y las funciones de penalización. También estudiaremos la clasificación multiclase y las variantes de este método en problemas de regresión.
- En la Sección 3, aplicaremos los conceptos adquiridos sobre varios casos prácticos mediante el lenguaje de programación R.

-
- Por último, en la Sección 4, extraeremos las conclusiones de los modelos estudiados en el capítulo anterior y analizaremos las ventajas y limitaciones de las SVM.

2. Fundamentos teóricos de las Máquinas de Vectores de Soporte

En el ámbito del análisis de datos y el Machine Learning, el aprendizaje supervisado consiste en deducir una función o regla a partir de un conjunto de datos cuya respuesta es conocida. Partimos de un conjunto formado por n individuos, denotado como $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$. En esta notación, cada $\mathbf{x}_i \in \mathbb{R}^p$ es un vector que contiene p observaciones o variables predictoras del individuo i -ésimo, mientras que y_i representa su variable respuesta u objetivo.

El tipo de problema al que nos enfrentamos depende de esta variable respuesta. Como se señala en [6], si y_i toma valores continuos, el problema es de regresión; por el contrario, si y_i es una variable categórica, nos encontramos ante un problema de clasificación. A lo largo de esta primera parte teórica centraremos nuestro estudio en este último caso, buscando asignar cada individuo a una clase predeterminada.

El principal desafío de cualquier modelo de clasificación no es únicamente acertar las clases del conjunto D , sino también identificar el patrón que permita predecir con exactitud la clase de datos futuros. Si un algoritmo diseña una frontera de decisión demasiado compleja y se ajusta excesivamente al ruido de los datos de entrenamiento, pierde su capacidad de generalización. Este fenómeno, conocido como sobreajuste u *overfitting*, es uno de los mayores problemas a evitar en el desarrollo de modelos predictivos.

Para solventar esta situación y construir un modelo resistente, la intuición sugiere buscar una frontera de decisión lineal que divida el espacio de características. Por ello, el primer paso para desarrollar la base de las Máquinas de Vectores de Soporte consiste en definir el objeto geométrico encargado de realizar esta separación.

2.1. Hiperplanos discriminantes

Definición 2.1 (Hiperplano) *Dado un espacio afín de dimensión p , un **hiperplano** es una variedad lineal plana de dimensión $p - 1$. En el espacio de características de p dimensiones, se define algebraicamente como el conjunto de puntos $\mathbf{x} = (x_1, \dots, x_p)^T \in \mathbb{R}^p$ que satisfacen la ecuación*

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (1)$$

donde $\mathbf{w} = (w_1, \dots, w_p)^T \in \mathbb{R}^p$ es el vector de pesos normal al hiperplano ($\mathbf{w} \neq \mathbf{0}$) y $b \in \mathbb{R}$ es el sesgo.

Definición 2.2 (Hiperplano discriminante) *Un **hiperplano discriminante** es aquel utilizado para dividir el espacio de individuos en subconjuntos disjuntos asociados a clases distintas.*

Para el caso de dos grupos G_1 y G_2 , el hiperplano clasifica a un individuo $\mathbf{x}_i$ en función del signo de $g(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b$, asignándolo a G_1 si $g(\mathbf{x}_i) < 0$ y a G_2 si $g(\mathbf{x}_i) > 0$.

Para simplificar la notación, en lugar de referirnos a G_1 y G_2 , restringiremos los valores de nuestra variable respuesta a $y_i \in \{-1, 1\}$, según el grupo al que pertenezca $\mathbf{x}_i$. Así, el producto $y_i \cdot g(\mathbf{x}_i)$ será siempre positivo si la clasificación es correcta.




Figura 1: Representación geométrica de un hiperplano discriminante en un espacio bidimensional (X_1, X_2) . La línea continua negra define la frontera de decisión donde $g(\mathbf{x}) = 0$. Esta recta divide el plano en dos regiones disjuntas, clasificando los individuos en un grupo u otro (puntos rojos y azules) en función del lado del hiperplano en el que se encuentren.

Observación 2.3 *Que $|g(\mathbf{x}_i)|$ sea muy grande implica (asumiendo una escala fija para el vector $\mathbf{w}$) que el individuo $\mathbf{x}_i$ se encuentra muy lejos de la frontera impuesta por el hiperplano. Por lo tanto, su evaluación probablemente será correcta.*

Sin embargo, cuanto menor sea el valor absoluto de $g(\mathbf{x}_i)$, tendremos menor certeza sobre si $\mathbf{x}_i$ se ha clasificado correctamente. También existe el caso $g(\mathbf{x}_i) = 0$, donde el punto caería exactamente sobre el hiperplano y provocaría ambigüedad en la clasificación. Para visualizar estos conceptos geoméricamente, la Figura 1 ilustra un hiperplano discriminante en un espacio bidimensional, donde la frontera de decisión separa a los individuos en sus respectivos grupos según el semiplano en el que se ubiquen.

2.2. Clasificadores de máximo margen

Definición 2.4 (Separabilidad Lineal) Sea un conjunto de datos de entrenamiento $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, donde $\mathbf{x}_i \in \mathbb{R}^p$ e $y_i \in \{-1, 1\}$, $i = 1, \dots, n$.

Diremos que este conjunto es **linealmente separable** si existe un vector de pesos $\mathbf{w} \in \mathbb{R}^p$ y un sesgo $b \in \mathbb{R}$ tales que se cumple la siguiente condición para todos los elementos:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0, \quad \forall i = 1, \dots, n$$

Geométricamente, esto implica que existe al menos un hiperplano capaz de separar perfectamente las clases sin cometer ningún error de clasificación.

Aunque el uso de hiperplanos discriminantes es un método válido para clasificar individuos, es preciso refinar esta técnica para encontrar la frontera de separación óptima cuando los datos sean linealmente separables.

Si encontramos una solución válida para separar los datos, existirán infinitos hiperplanos discriminantes (obtenidos mediante pequeñas rotaciones o traslaciones). Para determinar la solución óptima, introducimos los siguientes conceptos:

Definición 2.5 (Margen) Se define el **margen**, denotado por M , como la distancia mínima perpendicular existente entre un hiperplano discriminante y los puntos del conjunto de entrenamiento más cercanos a dicho hiperplano.

Definición 2.6 (Clasificador de máximo margen) Un **clasificador de máximo margen** es el método que asigna un nuevo individuo a una clase según el lado en el que se sitúe respecto al hiperplano de máximo margen. Este hiperplano óptimo es el que separe perfectamente las clases logrando que la distancia M a los puntos más cercanos sea máxima.

Si $w_1, w_2, \dots, w_p, b$ son los coeficientes de nuestro hiperplano de máximo margen, cada individuo $\mathbf{x}_i$ será clasificado en función del signo de $g(\mathbf{x}_i)$.

Recordemos que la distancia perpendicular de un punto $\mathbf{x}_i$ a un hiperplano definido por $\mathbf{w}^T \mathbf{x} + b = 0$ viene dada por:

$$d_i = \frac{y_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|} \quad (2)$$

Para plantear el problema de optimización, debemos eliminar la ambigüedad de escala que presentan los parámetros $\mathbf{w}$ y b . Una forma de hacerlo es imponer una restricción

sobre el vector de pesos exigiendo que sea unitario, es decir,

$$\|\mathbf{w}\| = \sqrt{\sum_{j=1}^n w_j^2} = 1$$

Bajo esta restricción, la distancia del punto $\mathbf{x}_i$ al hiperplano se simplifica a:

$$d_i = y_i(\mathbf{w}^T \mathbf{x}_i + b)$$

Nuestro objetivo entonces es encontrar el mayor margen M posible tal que todos los puntos se encuentren al menos a esa distancia M del hiperplano. El hiperplano de máximo margen vendrá dado por la solución al siguiente problema de optimización [5, 1]:

$$\begin{aligned} (P_1) \quad & \text{Max} \quad M \\ & \text{s.a} \quad \|\mathbf{w}\|^2 = 1, \end{aligned} \tag{3}$$

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq M \quad \forall i = 1, \dots, n \tag{4}$$

Cabe mencionar que en la restricción (3), en lugar de emplear $\|\mathbf{w}\|$, tomamos su cuadrado ($\sum_{j=1}^p w_j^2$) porque elevar al cuadrado es una transformación monótona. Por lo tanto, la solución óptima no varía y dicha restricción queda simplificada.

La solución a este problema nos proporciona el hiperplano óptimo único, aquel que separa los datos con el máximo margen posible. Cada elemento estará en el lado correcto del hiperplano y (P_1) escoge los coeficientes $w_1, \dots, w_p$ y b tales que la distancia M sea máxima.

2.2.1. Vectores de Soporte

Una propiedad fundamental de la solución obtenida en el problema de optimización (P_1) es que el hiperplano resultante no depende de la totalidad de los datos de entrenamiento, sino únicamente de un subconjunto de ellos.

Observando las restricciones del problema, notamos que para la mayoría de los individuos se cumplirá la desigualdad de forma estricta:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) > M$$

Esto indica que dichos puntos están “seguros”, lejos de la frontera de decisión. Sin embargo, existirá un pequeño grupo de elementos para los cuales la igualdad se satisface exactamente:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) = M$$

Definición 2.7 (Vector de soporte) *Los **vectores de soporte** son el subconjunto de individuos del conjunto de entrenamiento que resultan determinantes para la construcción del modelo. Se trata de aquellos puntos cuya eliminación o modificación alteraría la solución óptima, mientras que no habría impacto alguno si se excluyera cualquier otro individuo.*

En este caso concreto del clasificador de máximo margen, esta condición implica que los vectores de soporte tan solo son aquellos individuos para los cuales la restricción del margen se satisface con igualdad. Es decir, son los puntos que se sitúan exactamente a la distancia mínima M del hiperplano. Como podemos deducir, necesariamente debe haber casos que cumplan esta igualdad ya que, de no ser así, podríamos “desplazar” el hiperplano hasta hacerlo tangente a uno de esos puntos, logrando así un margen M mayor.

Geométricamente, los vectores de soporte son los elementos que sostienen el margen. Si eliminásemos del conjunto de datos cualquier elemento que no fuera un vector de soporte, el hiperplano óptimo no cambiaría en absoluto. Por el contrario, mover o eliminar un vector de soporte alteraría inmediatamente la solución. Como se ilustra en la Figura 2, estos vectores se corresponden con los puntos que descansan sobre los límites del margen.




Figura 2: Clasificador de máximo margen para un conjunto linealmente separable. La línea gruesa representa el hiperplano óptimo, mientras que las regiones sombreadas y las líneas discontinuas delimitan el margen máximo M . Las flechas se sitúan sobre los vectores de soporte, los únicos responsables de determinar la frontera de decisión.

2.2.2. El caso no separable

Hasta este punto, hemos asumido la hipótesis de que el conjunto de datos es linealmente separable. Sin embargo, en la práctica, esto rara vez ocurre. Los datos reales suelen presentar solapamiento entre clases o contener individuos atípicos.

Si intentamos aplicar el clasificador de margen máximo ya descrito a un conjunto de datos no separable, nos encontraremos con que la solución del problema (P_1) es un conjunto vacío: no existen $\mathbf{w}$ y b que puedan satisfacer todas las restricciones de desigualdad simultáneamente, es decir, no hay ningún hiperplano que separe los datos sin cometer ningún error (tal y como indica la Figura 3).





Figura 3: Ejemplo de un conjunto de datos donde las clases se solapan. En este escenario, la hipótesis de separabilidad lineal falla, haciendo imposible encontrar un hiperplano que clasifique todos los individuos correctamente.

Además, incluso si los datos fueran separables, buscar un margen que clasifique todo perfectamente puede llevar al sobreajuste, como se observa en la comparación de la Figura 4.

Para solucionar este problema, es necesario relajar las restricciones del problema de optimización. Esto da lugar al concepto de **clasificador de vectores de soporte**, que introduciremos a continuación.



(a) Hiperplano óptimo original.

(b) Nuevo hiperplano tras añadir un valor atípico.

Figura 4: Ilustración de la sensibilidad del clasificador de máximo margen. Izquierda: frontera de decisión para un conjunto de datos separable. Derecha: la introducción de un solo punto desplaza drásticamente el hiperplano y estrecha el margen, demostrando la inestabilidad de buscar una separación estricta.

2.3. Clasificadores de vectores de soporte

Los clasificadores de vectores de soporte, introducidos originalmente por Cortes y Vapnik [4], surgen tras generalizar los clasificadores de margen maximal a conjuntos de datos no linealmente separables. La principal diferencia con el caso anterior es que ahora permitiremos que algunos elementos sobrepasen el margen, o incluso que sean mal clasificados, a cambio de hacerlo mejor con el resto de individuos.

El modo de actuar consiste en “suavizar” el margen M con cierta tolerancia T de manera que algunos elementos sean mal clasificados sin sobrepasar dicha tolerancia. Este clasificador lo obtenemos resolviendo el problema de optimización

$$(P_2) \quad \text{Max} \quad M$$

$$\text{s.a} \quad \|\mathbf{w}\|^2 = 1, \quad (5)$$

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq M(1 - \varepsilon_i) \quad \forall i = 1, \dots, n \quad (6)$$

$$\varepsilon_i \geq 0 \quad \forall i = 1, \dots, n \quad (7)$$

$$\sum_{i=1}^n \varepsilon_i \leq T \quad (8)$$

donde T representa la tolerancia y cada ε_i corresponde a una variable de holgura con la función de aceptar que el individuo $\mathbf{x}_i$ se halle en el lado incorrecto del hiperplano o del margen. De igual manera al problema (P_1) , clasificaremos el dato según el signo de $g(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b$.


Observación 2.8 *En concreto, el individuo $\mathbf{x}_i$ puede situarse en cuatro zonas distintas:*

- a) Si el individuo se encuentra en el lado correcto del hiperplano, fuera del margen, $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq M \Rightarrow \varepsilon_i = 0$. Es el caso de la sección anterior.*
- b) Si el individuo se encuentra en el lado correcto del hiperplano, pero dentro del margen, $0 < y_i(\mathbf{w}^T \mathbf{x}_i + b) < M \Rightarrow 0 < \varepsilon_i < 1$. Sería un vector de soporte.*
- c) Si el individuo se encuentra exactamente sobre el hiperplano, $\mathbf{w}^T \mathbf{x}_i + b = 0$ (debe cumplir la ecuación del hiperplano) $\Rightarrow \varepsilon_i = 1$.*
- d) Si el individuo se encuentra al otro lado del hiperplano, $y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0$, ya que y_i está definida tal que $y_i \cdot g(\mathbf{x}_i)$ es siempre positivo cuando se clasifica correctamente al individuo. Por lo tanto, $\varepsilon_i > 1$, dando lugar a una clasificación errónea.*

Por otro lado, el hiperparámetro T se encarga de acotar la suma de los ε_i . Podríamos decir que su función es actuar como el coste máximo para el cual los n elementos $\mathbf{x}_i$ pueden sobrepasar el margen o el hiperplano (generalmente, un valor adecuado para la cota T se obtiene mediante validación cruzada). Si $T = 0$, todos los ε_i valdrán 0, lo cual nos lleva al problema (P_1) . En cambio, si $T > 0$, no puede haber más de T individuos en el lado incorrecto del hiperplano. El motivo es que una mala clasificación de $\mathbf{x}_i$ implica $\varepsilon_i > 1$. Si se cometieran T errores de clasificación tendríamos $\sum_{i=1}^n \varepsilon_i > T$, lo cual contradice la restricción (8). Por lo tanto, aumentar el valor de T permite que el margen sea sobrepasado en un mayor número de ocasiones y, en consecuencia, dicho margen será más ancho.

Otro importante aspecto del hiperparámetro T es su relación con el sesgo y la varianza del modelo. Si T es bajo, el margen será estrecho, tratando de evitar errores en la clasificación de los individuos. En consecuencia, su sesgo será mínimo. Sin embargo, el modelo será inestable porque su varianza será elevada: alguna modificación de los datos o la aparición de valores atípicos cambiaría el hiperplano y su margen drásticamente. En resumen, se daría un problema de sobreajuste, tal y como se indica en la Figura 5a.

En caso contrario, tendríamos un mayor margen con un valor grande de T . Al modelo no le supondría un problema que varios individuos estén mal clasificados, ignorando en cierta medida los datos con tal de proporcionar una frontera sencilla. El hiperplano será más estable (baja varianza) pero sesgado dada su simplicidad. En este caso, el modelo no habría aprendido lo suficiente del conjunto de datos [6], situación que ilustra la Figura 5b.



(a) Margen estrecho (baja tolerancia, T pequeño).

(b) Margen ancho (alta tolerancia, T grande).

Figura 5: Efecto del hiperparámetro de tolerancia T sobre la frontera de decisión que establece el clasificador de vectores de soporte. (a) Una T reducida estrecha el margen para penalizar los errores, ajustándose estrictamente a la muestra (menor sesgo, alto riesgo de sobreajuste). (b) Una T elevada genera un margen ancho que permite más violaciones (mayor sesgo, menor varianza).

La gran propiedad del problema (P_2) es que únicamente los elementos que sobrepasen el margen influirán en él, y, por lo tanto, en el clasificador obtenido. Mover los individuos correctamente clasificados a lo largo de la zona en la que se encuentran no modificaría el clasificador de vectores de soporte. En este modelo, los vectores de soporte son los puntos situados sobre el margen o traspasándolo, incluyendo aquellos en el lado incorrecto del hiperplano. Cuanto mayor sea el margen (mayor valor de T), habrá más vectores de soporte y viceversa.

2.3.1. Formulación dual y condiciones de optimalidad

Para poder calcular la solución del clasificador de vectores de soporte de manera eficiente y descubrir sus propiedades analíticas, debemos reformular el problema (P_2). Por las propiedades de invarianza de escala de los hiperplanos, sabemos que maximizar la distancia M es equivalente a minimizar la norma del vector de pesos $\|\mathbf{w}\|$, como indican las ecuaciones (2) y (4).

Aprovechando esta equivalencia, podemos reescribir el problema de optimización general en su forma convexa. Así es mucho más manejable analíticamente y nos permitirá descubrir una propiedad fundamental sobre cómo interactúa el algoritmo con los datos.

Consideremos el problema de minimización equivalente:

$$(P_2') \quad \text{Min} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \varepsilon_i$$

$$\text{s.a.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \varepsilon_i \quad \forall i = 1, \dots, n \quad (9)$$

$$\varepsilon_i \geq 0 \quad \forall i = 1, \dots, n \quad (10)$$

Nota: Al reformular el problema, en lugar de utilizar un “presupuesto” máximo de tolerancia T , lo usual (y la forma implementada de la librería `e1071` en R, según Karatzoglou [7]) es introducir un hiperparámetro de penalización C . Bajo esta notación, C actúa de forma inversamente proporcional a la tolerancia T : un valor alto de C implica una dura penalización de los errores, forzando un margen más estrecho y ajustado a los datos (mayor varianza y menor sesgo). Por el contrario, un valor bajo de C abarata el coste de los errores, permitiendo un margen más amplio.

Para resolver (P_2') , construimos el lagrangiano introduciendo los multiplicadores de Lagrange $\alpha_i \geq 0$ y $\mu_i \geq 0$ (asociados a las restricciones (9) y (10), respectivamente):

$$\mathcal{L}(\mathbf{w}, b, \varepsilon, \alpha, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \varepsilon_i - \sum_{i=1}^n \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \varepsilon_i] - \sum_{i=1}^n \mu_i \varepsilon_i \quad (11)$$

Para encontrar el mínimo del problema, derivamos $\mathcal{L}$ respecto a $\mathbf{w}$, b y las variables de holgura ε_i e igualamos a cero:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 \implies \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad (12)$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0 \implies \sum_{i=1}^n \alpha_i y_i = 0 \quad (13)$$

$$\frac{\partial \mathcal{L}}{\partial \varepsilon_i} = C - \alpha_i - \mu_i = 0 \implies \alpha_i + \mu_i = C \quad (14)$$

La ecuación (14) desvela una propiedad importante sobre los multiplicadores. Dado que $\mu_i \geq 0$ y $\alpha_i \geq 0$, necesariamente se debe cumplir que $0 \leq \alpha_i \leq C$.

A continuación, sustituimos estas relaciones en el lagrangiano (11) para obtener la función dual. Observamos un detalle crucial: los términos que dependen de ε_i se cancelan gracias a la condición (14):

$$\sum_{i=1}^n \varepsilon_i (C - \alpha_i - \mu_i) = \sum_{i=1}^n \varepsilon_i (0) = 0$$

Por lo tanto, las variables de holgura ε_i desaparecen de la ecuación y, al sustituir la expresión de $\mathbf{w}$ en el término $\frac{1}{2}\|\mathbf{w}\|^2$, demostramos la dependencia del producto escalar:

$$\frac{1}{2}\|\mathbf{w}\|^2 = \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{j=1}^n \alpha_j y_j \mathbf{x}_j \right) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x}_j)$$

ya que $\mathbf{x}_i^T \mathbf{x}_j = \langle \mathbf{x}_i, \mathbf{x}_j \rangle$.

Finalmente, planteamos la función objetivo dual a maximizar (y a partir de la cual hallaremos los valores de α_i):

$$\begin{aligned} (\text{D}_1) \quad \text{Max} \quad \tilde{\mathcal{L}}(\alpha) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x}_j) \\ \text{s.a} \quad 0 &\leq \alpha_i \leq C, \quad \forall i = 1, \dots, n \\ \sum_{i=1}^n \alpha_i y_i &= 0 \end{aligned} \tag{15}$$

La expresión (15) revela la propiedad que buscábamos: el problema de optimización depende de los datos exclusivamente a través de su producto escalar $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ ($i, j = 1, \dots, n$).

Recordemos que los individuos se clasifican según la función $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$. Sustituyendo $\mathbf{w}$ en la ecuación (12), obtenemos

$$g(\mathbf{x}) = \left(\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \right)^T \mathbf{x} + b = b + \sum_{i=1}^n \alpha_i y_i (\mathbf{x}_i^T \mathbf{x})$$

En consecuencia, podemos representar el clasificador de vectores de soporte como

$$g(\mathbf{x}) = b + \sum_{i=1}^n \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle \tag{16}$$

Para obtener los parámetros $b, \alpha_1, \dots, \alpha_n$, debemos calcular $\frac{n(n+1)}{2}$ productos escalares. Sin embargo, este cálculo puede simplificarse en gran medida aplicando las condiciones de Karush-Kuhn-Tucker (KKT) en el problema (P₂'), tal y como se detalla en [5, 1].

En particular, las condiciones de holgura complementaria establecen que, en el óptimo del problema, el producto entre cada multiplicador de Lagrange y su restricción asociada debe ser cero para cada elemento i . Esto se traduce en dos ecuaciones, una para la restricción de los márgenes y otra análoga para la no negatividad de los errores:

$$\alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \varepsilon_i] = 0 \tag{17}$$

$$\mu_i \varepsilon_i = 0 \quad (18)$$

Esta propiedad es fundamental: para cualquier punto que esté correctamente clasificado y estrictamente fuera de los márgenes, el término entre corchetes en (17) es distinto de cero, lo que obliga matemáticamente a que su multiplicador sea $\alpha_i = 0$. En conjunto, el cumplimiento de estas condiciones de holgura divide a los datos en tres posibles situaciones geométricas:

- Si el individuo está bien clasificado y fuera del margen, vimos que la restricción se cumple con desigualdad estricta y $\varepsilon_i = 0$. Por lo tanto, el término entre corchetes en (17) es distinto de cero, siguiéndose que obligatoriamente $\alpha_i = 0$.
- Si el individuo está situado sobre el margen, cumple la restricción con igualdad estricta. Se anula el término entre corchetes, dando lugar a $0 < \alpha_i < C$.
- Si el individuo invade el margen o está mal clasificado, $\varepsilon_i > 0$. Sin embargo, como el problema primal busca minimizar la suma de estos errores (penalizados por el hiperparámetro C), ε_i tendrá el menor valor tal que la restricción (9) se cumpla en su límite inferior. Esto fuerza la igualdad, anulando de nuevo el corchete. En consecuencia, $\mu_i = 0$ por (18) y su multiplicador alcanza el límite superior, $\alpha_i = C$, según (14).

De este modo, la regla de clasificación final depende exclusivamente del conjunto de vectores de soporte, denotado como $\mathcal{S}$:

$$g(\mathbf{x}) = b + \sum_{i \in \mathcal{S}} \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle \quad (19)$$

Para poder evaluar esta función de decisión en la práctica, tan solo nos falta calcular el valor del sesgo b . Para ello, utilizamos los vectores de soporte situados exactamente sobre los márgenes, es decir, aquellos que cumplen $0 < \alpha_i < C$. Para estos puntos, $\varepsilon_i = 0$ y el término entre corchetes de la ecuación (17) se anula, cumpliéndose la restricción:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0$$

Teniendo en cuenta que $y_i^2 = 1$, podemos despejar el parámetro b :

$$b = y_i - \mathbf{w}^T \mathbf{x}_i = y_i - \sum_{j=1}^n \alpha_j y_j \langle \mathbf{x}_j, \mathbf{x}_i \rangle \quad (20)$$

2.4. Máquinas de Vectores de Soporte

El clasificador de vectores de soporte obtenido tras resolver el problema (P_2') funciona especialmente bien cuando trabajamos con dos clases y la frontera entre estas es mayoritariamente lineal. Sin embargo, podemos encontrarnos con conjuntos de datos cuya frontera no es de este tipo. En estos casos, la actuación del clasificador es poco precisa, como podemos observar en la Figura 6.




Figura 6: Clasificador de vectores de soporte sobre un conjunto de datos con frontera no lineal. Se cometen numerosos errores de clasificación en ambos grupos debido a la rigidez de la frontera de decisión.

Las máquinas de vectores de soporte (SVM) son una generalización del clasificador de vectores de soporte que amplían el espacio original de características para ajustar fronteras no lineales entre clases. A esta transformación, que proyecta los datos a un espacio de mayor dimensión, se la denota mediante la función vectorial no lineal ϕ .

Al aplicar esta generalización, el problema de optimización primal (P_2') que habíamos definido para el caso lineal se mantiene idéntico, con las diferencias de que ahora operamos sobre $\phi(\mathbf{x})$ en lugar de sobre $\mathbf{x}$ y el vector de pesos $\mathbf{w}$ tiene la misma dimensión que el espacio ampliado:

$$\begin{aligned}
 (P_3) \quad & \text{Min} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \varepsilon_i \\
 \text{s.a} \quad & y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \varepsilon_i \quad \forall i = 1, \dots, n \\
 & \varepsilon_i \geq 0 \quad \forall i = 1, \dots, n
 \end{aligned}
 \tag{21}$$

$$\tag{22}$$

Si resolviéramos este problema aplicando la formulación dual que vimos en la sección anterior, la función g dependería exclusivamente del producto escalar de los datos en el nuevo espacio:

$$g(\mathbf{x}) = b + \sum_{j \in \mathcal{S}} \alpha_j y_j \langle \phi(\mathbf{x}_j), \phi(\mathbf{x}) \rangle \quad (23)$$

Ampliar el espacio de características de esta forma permite trazar fronteras muy diversas. No obstante, si quisiéramos usar polinomios de grado muy alto, la dimensión del nuevo vector $\phi(\mathbf{x})$ crecería exponencialmente, haciendo que el cálculo explícito de su producto escalar conlleve un coste computacional enorme. Es aquí donde descubrimos la verdadera potencia de las SVM mediante el uso del *kernel* [1].

Definición 2.9 *Dado $\mathcal{X}$ el espacio de individuos de un conjunto de datos, un **kernel** es una función simétrica y semidefinida positiva $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ para la cual existe un espacio de características $\mathcal{V}$ dotado de producto escalar y una transformación $\phi : \mathcal{X} \rightarrow \mathcal{V}$ tal que, para cualesquiera $\mathbf{x}_i, \mathbf{x}_j \in \mathcal{X}$,*

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle \quad (24)$$

Esto evita por completo el coste computacional de aplicar explícitamente la transformación ϕ a cada elemento. Gracias al kernel, la expresión (23) se convierte en

$$g(\mathbf{x}) = b + \sum_{j \in \mathcal{S}} \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}) \quad (25)$$

La función K evalúa el producto interno en el espacio transformado operando directamente sobre los vectores en el espacio original. De esta forma, no es necesario calcular explícitamente los valores $\phi(\mathbf{x}_j)$ y $\phi(\mathbf{x})$ para determinar $g(\mathbf{x})$; nos basta con obtener su producto escalar.

2.4.1. Tipos de kernel

La labor del kernel puede interpretarse como una cuantificación de la similitud entre dos elementos. Existen diversos tipos de funciones kernel, siendo cada una más o menos adecuada en función de la representación que tome nuestro conjunto de datos. A continuación estudiaremos las elecciones más utilizadas para SVM en la práctica [6].

Kernel lineal

Es el kernel básico. El kernel lineal se define simplemente como el producto escalar en el espacio original:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle \quad (26)$$

Es el caso del modelo lineal que hemos estudiado hasta ahora. Sin embargo, pierde eficiencia para problemas donde las clases no son linealmente separables.

En la práctica, el kernel lineal resulta especialmente útil cuando se trabaja con datos dispersos y de gran dimensión, como suele ocurrir en problemas de categorización y minería de textos [7].

Kernel polinómico

Si nuestros datos presentan una frontera no lineal, podríamos sustituir $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ por la expresión

$$K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \langle \mathbf{x}_i, \mathbf{x}_j \rangle)^d \quad (27)$$

Este kernel se conoce como *kernel polinómico de grado d* , donde d es un entero positivo. Si $d = 1$, tendríamos de nuevo un kernel lineal. En cambio, cuando $d > 1$, obtenemos una frontera mucho más flexible para separar de mejor manera las clases. El algoritmo funciona igual que calculando todas las combinaciones entre individuos en el espacio de mayor dimensión, pero ahorrándose este costoso cálculo.

Al tratarse de un clasificador de vectores de soporte combinado con un kernel no lineal, el resultado es una SVM. En la Figura 7 se muestra un ejemplo de kernel polinómico:

Gracias a su capacidad para analizar características de orden superior, este tipo de transformación es muy popular y ofrece grandes resultados en tareas de procesamiento de imágenes [7].

Kernel con función de base radial (RBF)

Hay ocasiones donde la frontera no tiene forma polinómica. En estos casos, podemos utilizar el *kernel radial*, también conocido como *kernel gaussiano*:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (28)$$

donde γ es una constante positiva. Al utilizar este kernel, los puntos que se encuentren lejos entre sí aumentarán el valor de la norma. Por lo tanto, el valor $K(\mathbf{x}_i, \mathbf{x}_j)$ será muy




Figura 7: SVM con kernel polinómico de grado 2. La frontera parabólica no comete ningún error de clasificación, mejorando la precisión del modelo obtenido por el kernel lineal. Los puntos con borde negro son los vectores de soporte, ya que invaden el margen impuesto por el clasificador.

pequeño y $g(\mathbf{x})$ también lo será. Por el contrario, dos puntos muy próximos en el espacio de individuos harán que la norma tienda a 0 y $K(\mathbf{x}_i, \mathbf{x}_j)$ tome un valor muy cercano a 1, el máximo de esta función. En consecuencia, $g(\mathbf{x})$ se encontrará lejos del 0, dando lugar a una probable correcta clasificación del individuo.

En resumen, el kernel radial tiene un comportamiento local: la clase del individuo depende de sus vecinos más cercanos, como se puede apreciar en la Figura 8. Es el kernel por defecto cuando no hay conocimiento previo sobre la distribución de los datos [7].

2.5. El enfoque de penalización y la función Hinge Loss

Por el momento, hemos estudiado las máquinas de vectores de soporte desde una perspectiva puramente geométrica, buscando maximizar el margen de separación entre clases. Sin embargo, es habitual reformular este algoritmo como un problema estándar de optimización sin restricciones basado en la minimización de una función de pérdida y penalización [5].

Redefiniendo nuestra función discriminante para que opere en el espacio de características ampliado, es decir, $g(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b$, consideremos el problema de optimización sin restricciones:




Figura 8: SVM con kernel gaussiano con el hiperparámetro $\gamma = 0.3$ que logra clasificar correctamente a todos los individuos. A diferencia del modelo polinómico, la frontera obtenida tras utilizar este kernel cambia de forma, “encerrando” los puntos azules.

$$(P_4) \quad \text{Min} \quad \sum_{i=1}^n [1 - y_i g(\mathbf{x}_i)]_+ + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (29)$$

donde el subíndice “+” indica la parte positiva de la expresión. Esta estructura tiene la forma clásica de *pérdida + penalización*, un modelo muy familiar en la estimación de funciones.

Definición 2.10 (Función Hinge Loss) La siguiente función de pérdida es conocida como *función de pérdida bisagra* (hinge loss):

$$L(y, g(\mathbf{x})) = [1 - y \cdot g(\mathbf{x})]_+ \quad (30)$$

La principal característica de esta función es que asigna una penalización nula a los individuos que están correctamente clasificados ($y_i \cdot g(\mathbf{x}_i) \geq 1$). Por el contrario, impone un coste lineal a los elementos que invaden el margen o caen en el lado equivocado de la frontera.

Comparando este enfoque estadístico con otros métodos de clasificación clásicos [5], encontramos diferencias que explican el comportamiento de las SVM (véase la Figura 9):

- **Frente a la regresión logística:** La función de pérdida de la regresión logística (conocida como devianza binomial) tiene un comportamiento asintótico similar en las colas, pero nunca se hace exactamente cero para los casos seguros situados

dentro del margen, teniendo que tomar en consideración todos los datos para realizar la clasificación. Sin embargo, nuestra función bisagra asigna un error de 0 a los individuos bien clasificados, reduciendo enormemente la cantidad de puntos que determinan la frontera. Además, la regresión logística estima una transformación de las probabilidades a posteriori de cada clase, mientras que la función *hinge loss* estima directamente la regla de clasificación final.

- **Frente al error cuadrático:** El error cuadrático penaliza de forma cuadrática a todos los puntos, de forma que incluso aquellos individuos que ya están correctamente clasificados y muy alejados de la frontera tienen un gran error. Por lo tanto, también presentan una fuerte influencia sobre el modelo final, desplazando la frontera hacia dichos puntos.




Figura 9: Comparación de distintas funciones de pérdida empleadas en clasificación. Se observa como la función *hinge loss* de las SVM penaliza linealmente los errores pero vale cero para los individuos correctamente clasificados y fuera del margen ($y \cdot g(\mathbf{x}) \geq 1$). Por el contrario, la desviación binomial de la regresión logística nunca alcanza el cero, y el error cuadrático penaliza a los individuos muy bien clasificados.

Finalmente, podemos demostrar de manera directa que la solución a este problema de optimización (P_4) es idéntica a la del problema primal (P_2') que definimos para el margen suave.

Para ello, recordemos las variables de holgura ε_i que introdujimos en dicho problema. Estas variables estaban sujetas a las restricciones (9) y (10):

$$\begin{aligned} y_i g(\mathbf{x}_i) \geq 1 - \varepsilon_i &\implies \varepsilon_i \geq 1 - y_i g(\mathbf{x}_i) \\ \varepsilon_i &\geq 0 \end{aligned} \tag{31}$$

Dado que el objetivo del problema (P_2') es minimizar, junto al margen, la suma de estas variables, en la solución óptima cada ε_i tomará el menor valor posible que satisfaga al mismo tiempo las desigualdades (10) y (31). Podemos expresar ese valor como:

$$\varepsilon_i = \max\{0, 1 - y_i g(\mathbf{x}_i)\} \quad (32)$$

Observamos que el valor óptimo de la variable de holgura coincide con la definición de la función *hinge loss*. Al sustituir esta equivalencia en la función objetivo (29), el problema sin restricciones toma la forma:

$$\min_{\mathbf{w}, b} \left\{ \sum_{i=1}^n \varepsilon_i + \frac{\lambda}{2} \|\mathbf{w}\|^2 \right\} \quad (33)$$

Dado que multiplicar la función objetivo por una constante estrictamente positiva no altera su óptimo, podemos multiplicar toda la expresión por $C = 1/\lambda$ (suponiendo $\lambda > 0$):

$$\min_{\mathbf{w}, b} \left\{ C \sum_{i=1}^n \varepsilon_i + \frac{1}{2} \|\mathbf{w}\|^2 \right\} \quad (34)$$

Esta expresión final es idéntica a la función objetivo del problema primal (P_2'), completando así la demostración y confirmando que la constante de regularización λ es inversamente proporcional al coste C . De este modo, podemos afirmar que λ y la tolerancia T actúan en la misma dirección: un mayor valor de λ implica un menor coste C , permitiendo un margen más amplio y suave.

2.6. Clasificación multiclase

Originalmente, las SVM se diseñaron para la clasificación binaria. Sin embargo, al llevarlas a la práctica lo habitual es encontrarse con más de dos clases en nuestro conjunto de datos. Para ello, se han desarrollado principalmente dos estrategias que abordan este problema y lo reducen a varias clasificaciones binarias [1].

Estrategia “Uno contra Todos”

La estrategia Uno contra Todos (One vs. Rest) fue propuesta por Vapnik [16]. Suponiendo que tenemos K distintos grupos $G_1, \dots, G_K$, se construyen K distintas SVM de manera que el k -ésimo modelo se entrena tomando como casos positivos aquellos individuos pertenecientes al grupo G_k , siendo los individuos de los $K - 1$ grupos restantes catalogados como casos negativos ($k = 1, \dots, K$).

Al evaluar un nuevo dato $\mathbf{x}_i$, cada modelo proporciona un valor de su función discriminante $g_k(\mathbf{x}_i)$. El individuo se asigna a la clase cuyo clasificador haya obtenido el valor más alto (mayor distancia al hiperplano), según la regla:

$$G(\mathbf{x}_i) = \arg \max_{k \in \{1, \dots, K\}} g_k(\mathbf{x}_i) \quad (35)$$

El principal problema que presenta esta estrategia es que los conjuntos de entrenamiento que genera cada modelo están muy desbalanceados: cada SVM toma únicamente la K -ésima parte del total de los datos como casos positivos [1]. Por otro lado, si los valores de $g_k(\mathbf{x})$ están en distinta escala para cada k , la función $G(\mathbf{x}_i)$ podría clasificar erróneamente a los individuos.

Estrategia “Uno contra Uno”

Bajo este enfoque, tomamos las $\binom{K}{2} = \frac{K(K-1)}{2}$ parejas que podemos formar entre los K grupos distintos y entrenamos una SVM binaria por cada una de estas combinaciones.

Para clasificar un nuevo individuo $\mathbf{x}_i$, este se evalúa en los $\frac{K(K-1)}{2}$ modelos. Cada clasificador binario emite un “voto” por la clase ganadora y el individuo se asignará al grupo que acumule el mayor número de votos totales en el conjunto de las clasificaciones. En caso de empate, los algoritmos suelen resolverlo asignando el dato a la primera clase que alcanzó dicho máximo.

Aunque esta estrategia requiere construir un mayor número de clasificadores si K es muy grande, en la práctica el tiempo total de procesamiento utilizado suele ser menor en comparación con el método Uno contra Todos. Esto se debe a que los subconjuntos de entrenamiento de cada pareja son mucho más pequeños, y el problema de optimización cuadrática de las SVM escala de forma superlineal¹ con el tamaño de los datos [7]. De este modo, se evita el problema de desbalanceo del enfoque anterior, haciéndolo mucho más estable y eficiente computacionalmente.

2.7. Máquinas de Vectores de Soporte para Regresión (SVR)

Para utilizar las SVM en el contexto de la regresión, lo primero que debemos hacer es modificar el enfoque inicial del hiperplano. En lugar de buscar un hiperplano que separe

¹La complejidad temporal del entrenamiento de una SVM suele ser del orden $\mathcal{O}(n^k)$, con k situado entre 1 y 2.5, donde n es el número de individuos [7]. Esto implica que resolver múltiples problemas de optimización sobre subconjuntos de datos pequeños resulta mucho más rápido que resolver un único problema global.

clases, ahora queremos hallar una función $f(\mathbf{x})$ que se ajuste a los puntos, pero siendo lo más plana posible.

La función que queremos estimar toma la siguiente forma, cuya expresión se asemeja a la de los hiperplanos discriminantes:

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \quad (36)$$

Tradicionalmente, los parámetros $\mathbf{w}$ y b se estiman minimizando una función de error cuadrático regularizada [1]:

$$\frac{1}{2} \sum_{i=1}^n (t_i - f(\mathbf{x}_i))^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (37)$$

donde $t_i \in \mathbb{R}$ es la variable objetivo para $\mathbf{x}_i$. El primer término mide el error en la predicción y el segundo es un término de regularización que trata de mantener plana la función.

Sin embargo, el error cuadrático es muy sensible a los valores atípicos. Para solventar esta situación, Vapnik realizó un cambio de enfoque: creó un “tubo” de tolerancia. Introducimos así la función de pérdida ε -insensible para $\varepsilon \geq 0$ [16]:

$$E_\varepsilon(t, f(\mathbf{x})) = \begin{cases} 0 & \text{si } |t - f(\mathbf{x})| \leq \varepsilon \\ |t - f(\mathbf{x})| - \varepsilon & \text{en caso contrario} \end{cases} \quad (38)$$

Esta formulación representa el análogo directo de la función de coste *hinge loss* estudiada en la Sección 2.5. De este modo, si un punto cae dentro del margen definido por ε , consideramos que su error es exactamente cero. Por ello, los vectores de soporte para la regresión serán aquellos individuos que se sitúen fuera del margen establecido por ε o justamente sobre su frontera, que se corresponden con los puntos con borde rojo en el ejemplo de la Figura 10.

Como estos vectores de soporte pueden encontrarse fuera del margen tanto por encima como por debajo de este, necesitamos definir dos nuevas variables de holgura no negativas para cada $\mathbf{x}_i$, las cuales denotaremos como ξ_i y ξ_i^* , respectivamente. Además, podemos apreciar que, dado que un punto no puede estar situado por encima y por debajo del margen al mismo tiempo, se cumple la condición de complementariedad:

$$\xi_i \cdot \xi_i^* = 0 \quad (39)$$




Figura 10: Esquema del tubo de ε -insensibilidad en la Regresión de Vectores de Soporte (SVR). Los puntos situados dentro del tubo de radio ε no contribuyen a la función de pérdida, mientras que los puntos exteriores (vectores de soporte) son penalizados según su distancia a la frontera del tubo. Esta penalización dependerá de las variables de holgura ξ_i y ξ_i^* .

El problema de optimización que se nos presenta es el siguiente [13]:

$$(P_5) \quad \text{Min} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

$$\text{s.a.} \quad t_i - \mathbf{w}^T \mathbf{x}_i - b \leq \varepsilon + \xi_i \quad \forall i = 1, \dots, n \quad (40)$$

$$\mathbf{w}^T \mathbf{x}_i + b - t_i \leq \varepsilon + \xi_i^* \quad \forall i = 1, \dots, n \quad (41)$$

$$\xi_i, \xi_i^* \geq 0 \quad \forall i = 1, \dots, n \quad (42)$$

donde el hiperparámetro $C > 0$ posee la misma labor regularizadora que en el caso de la clasificación, controlando la relación entre la suavidad de la función y la penalización por los errores tolerados.

El primer paso para resolver (P_5) es construir la función lagrangiana introduciendo los multiplicadores de Lagrange $\alpha_i, \alpha_i^*, \eta_i, \eta_i^* \geq 0$:

$$\begin{aligned} \mathcal{L}(\mathbf{w}, b, \xi, \xi^*, \alpha, \alpha^*, \eta, \eta^*) = & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) - \sum_{i=1}^n (\eta_i \xi_i + \eta_i^* \xi_i^*) \\ & - \sum_{i=1}^n \alpha_i (\varepsilon + \xi_i - t_i + \mathbf{w}^T \mathbf{x}_i + b) - \sum_{i=1}^n \alpha_i^* (\varepsilon + \xi_i^* + t_i - \mathbf{w}^T \mathbf{x}_i - b) \end{aligned} \quad (43)$$

Para hallar el mínimo del problema, de forma análoga al problema (P_3) , derivamos $\mathcal{L}$ respecto a $\mathbf{w}$, b y las variables ξ_i, ξ_i^* para después igualar las derivadas a cero:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^n \alpha_i \mathbf{x}_i + \sum_{i=1}^n \alpha_i^* \mathbf{x}_i = 0 \implies \mathbf{w} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i \quad (44)$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \alpha_i + \sum_{i=1}^n \alpha_i^* = 0 \implies \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0 \quad (45)$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \eta_i - \alpha_i = 0 \implies \alpha_i + \eta_i = C \quad (46)$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i^*} = C - \eta_i^* - \alpha_i^* = 0 \implies \alpha_i^* + \eta_i^* = C \quad (47)$$

Sustituyendo las igualdades (45), (46) y (47) en (43), el lagrangiano ya no depende de b, ξ, ξ^*, η ni η^* , resultando en la siguiente expresión:

$$L(\mathbf{w}, \alpha, \alpha^*) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (\varepsilon - t_i + \mathbf{w}^T \mathbf{x}_i) - \sum_{i=1}^n \alpha_i^* (\varepsilon + t_i - \mathbf{w}^T \mathbf{x}_i)$$

En un segundo paso, podemos observar que, extrayendo $\mathbf{w}^T$ como factor común, el último término de ambos sumatorios coincide con el valor de $\mathbf{w}$ obtenido en la ecuación (44). Al sustituir esta condición, este último término se transforma en $-\|\mathbf{w}\|^2$, lo que nos permite agruparlo con el primer sumando de la ecuación:

$$L(\mathbf{w}, \alpha, \alpha^*) = -\frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (\varepsilon - t_i) - \sum_{i=1}^n \alpha_i^* (\varepsilon + t_i)$$

Si desarrollamos la norma de $\mathbf{w}$ según aparece en (44), eliminamos la última variable del problema primal:

$$-\frac{1}{2} \|\mathbf{w}\|^2 = -\frac{1}{2} \left\| \sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i \right\|^2 = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) (\mathbf{x}_i^T \mathbf{x}_j)$$

Ahora ya podemos formular el problema dual, que es el siguiente:

$$\begin{aligned} (D_2) \quad \text{Max} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) (\mathbf{x}_i^T \mathbf{x}_j) - \varepsilon \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n t_i (\alpha_i - \alpha_i^*) \\ \text{s.a} \quad & \sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0 \\ & 0 \leq \alpha_i, \alpha_i^* \leq C \quad \forall i = 1, \dots, n \end{aligned} \quad (48)$$

cuya primera restricción es la ecuación (45) y la segunda se deduce tras aplicar el hecho de que $\eta_i, \eta_i^* \geq 0$ en (46) y (47).

Observamos que, de manera análoga al problema dual para el caso de la clasificación, la función objetivo vuelve a depender de los datos únicamente a través de sus productos escalares. Al resolver este problema de optimización cuadrática, el algoritmo encuentra los valores óptimos para los multiplicadores α_i y α_i^* .

Si sustituimos la expresión (44) en nuestra función de regresión, tenemos:

$$f(\mathbf{x}) = \left(\sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i \right)^T \mathbf{x} + b = b + \sum_{i=1}^n (\alpha_i - \alpha_i^*) (\mathbf{x}_i^T \mathbf{x})$$

Por lo tanto, podemos aplicar el truco del kernel y hallar la expresión general de la función de regresión final

$$f(\mathbf{x}) = b + \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(\mathbf{x}_i, \mathbf{x}) \quad (49)$$

donde hay $2n$ parámetros α_i, α_i^* con $i = 1, \dots, n$.

Lo único que resta por determinar es el valor del sesgo b . Para ello, aplicamos las condiciones de holgura complementaria de KKT al problema primal (P_5):

$$\alpha_i(\varepsilon + \xi_i - t_i + \mathbf{w}^T \mathbf{x}_i + b) = 0 \quad (50)$$

$$\alpha_i^*(\varepsilon + \xi_i^* + t_i - \mathbf{w}^T \mathbf{x}_i - b) = 0 \quad (51)$$

$$\eta_i \xi_i = 0 \quad (52)$$

$$\eta_i^* \xi_i^* = 0 \quad (53)$$

A diferencia de la clasificación, en la regresión por vectores de soporte el tubo ε posee dos fronteras independientes: el límite superior y el límite inferior. Por lo tanto, las condiciones de complementariedad se duplican, dando lugar a cuatro ecuaciones: dos para las fronteras del tubo y dos para la no negatividad de los errores.

Supongamos, sin pérdida de generalidad, que los puntos están ubicados por encima de su posición esperada. Analizando los posibles casos en los que puede situarse un dato de entrenamiento, observamos lo siguiente:

- Si la predicción está dentro del tubo, esta tiene un error menor que ε y los paréntesis de las ecuaciones (50) y (51) no pueden ser cero. Por consiguiente, para cumplirse igualdad, necesariamente $\alpha_i = \alpha_i^* = 0$.

- Si la predicción se sitúa sobre la frontera del tubo, el error es igual a la tolerancia ε , por lo que no existe holgura y $\xi_i = 0$. Por lo tanto, sus multiplicadores toman un valor intermedio tal que $0 < \alpha_i < C$.
- Si la predicción se encuentra fuera del tubo, el error es mayor que la tolerancia ε , haciendo que ξ_i sea estrictamente positiva. Este hecho fuerza a η_i a valer cero por (52) y (53). Consecuentemente, por (46), $\alpha_i = C$.

Concluimos que los vectores de soporte son los individuos con multiplicadores no nulos, es decir, aquellos que no están estrictamente dentro del tubo. Denotando de nuevo a este subconjunto de vectores de soporte como $\mathcal{S}$, la mayoría de los puntos del conjunto de entrenamiento tendrán multiplicadores nulos ($\alpha_i = \alpha_i^* = 0$) y desaparecerán de la ecuación (49), puesto que caerán dentro del tubo de tolerancia.

Así, la función de regresión final depende únicamente de una pequeña fracción de los datos originales:

$$f(\mathbf{x}) = b + \sum_{i \in \mathcal{S}} (\alpha_i - \alpha_i^*) K(\mathbf{x}_i, \mathbf{x}) \quad (54)$$

Por último, para calcular el valor exacto del sesgo b , nos es imposible utilizar los vectores de soporte exteriores al tubo debido a que el valor de ξ_i es desconocido a priori. En consecuencia, debemos recurrir a los vectores de soporte situados exactamente sobre la frontera ya que para esos puntos $\xi_i = 0$.

Tomando un vector de soporte $\mathbf{x}_i$ de la frontera superior, $0 < \alpha_i < C$, así que el paréntesis de (50) debe ser igual a 0. Sustituyendo el producto escalar por la función kernel K , despejamos b :

$$b = t_i - \varepsilon - \sum_{j=1}^n (\alpha_j - \alpha_j^*) K(\mathbf{x}_j, \mathbf{x}_i) \quad (55)$$

Análogamente, para un punto situado exactamente en la frontera inferior obtenemos:

$$b = t_i + \varepsilon - \sum_{j=1}^n (\alpha_j - \alpha_j^*) K(\mathbf{x}_j, \mathbf{x}_i) \quad (56)$$

En la práctica, para garantizar la máxima estabilidad numérica frente a pequeños errores de precisión computacional, el modelo calcula el valor definitivo de b promediando los resultados obtenidos al aplicar estas fórmulas sobre todos los vectores de soporte situados en ambas fronteras [1].

Llegados a este punto, observamos que la función de regresión final (54) preserva la potencia de las SVM originales. Al depender los cálculos exclusivamente del producto escalar, podemos emplear las mismas funciones kernel expuestas en la Sección 2.4.1. Esto dota a la SVR de una gran flexibilidad, permitiéndole modelar y ajustar curvas no lineales a conjuntos de datos complejos.

3. Aplicación práctica de SVM en R

Una vez tratados los fundamentos teóricos y matemáticos de las SVM en la sección anterior, el objetivo de este bloque es evaluar el rendimiento de este algoritmo en situaciones reales. Para ello, utilizaremos el lenguaje de programación R, empleando principalmente la librería `e1071` [9].

A lo largo de este capítulo, describiremos la metodología de evaluación y el software utilizado para posteriormente aplicar el algoritmo en tres escenarios distintos: clasificación binaria, clasificación multiclase y regresión de vectores de soporte (SVR). Este enfoque nos permitirá validar la teoría expuesta al igual que analizar la sensibilidad del modelo ante la elección de distintos kernels e hiperparámetros.

3.1. Metodología y software a utilizar

En esta sección, detallaremos el procedimiento y las herramientas informáticas que vamos a utilizar a lo largo de esta parte práctica.

3.1.1. Metodología de evaluación

Para validar la capacidad de generalización de los modelos, seguiremos tres pasos:

- En primer lugar, realizaremos una división de nuestro conjunto de datos en dos subconjuntos independientes: entrenamiento (*train*, 70 % del total) y prueba (*test*, 30 % restante) a partir del paquete `caret` [8]. Utilizaremos el primero para ajustar los parámetros y evaluaremos el rendimiento final con los datos del segundo.
- A continuación, estandarizaremos las variables del conjunto de entrenamiento para que todas tengan media 0 y varianza 1. Este paso resulta crucial para el funcionamiento correcto de la SVM, pues son extremadamente sensibles a la escala de las variables dado que calculan distancias geométricas entre individuos. Como se señala en [7], las librerías de R que utilizaremos aplican esta transformación por defecto.
- Por último, buscaremos optimizar los hiperparámetros en lugar de seleccionarlos arbitrariamente. En lugar de reservar un tercer subconjunto para la validación del modelo entrenado (lo cual reduciría el volumen de datos disponibles para el aprendizaje), utilizaremos una validación cruzada de 10 particiones. De esta forma, podremos determinar la combinación que minimice el error de validación evitando el *overfitting* [6, 7].

3.1.2. Métricas de rendimiento

Para determinar la calidad de las predicciones, analizaremos el rendimiento de cada kernel sobre el conjunto de test. Las métricas de evaluación se adaptarán a la clase de problema que abordemos, priorizando el modelo más simple en caso de haber dos o más con métricas similares.

En problemas de clasificación

Partiremos de la construcción de la matriz de confusión, la cual clasifica las predicciones en cuatro categorías: Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN). A partir de estos valores, en lugar de limitarnos a la exactitud (*accuracy*), que mide la cantidad de aciertos entre el total de individuos, calcularemos las siguientes métricas:

- **Precisión (*Precision*)**: mide la proporción de clasificaciones positivas que fueron correctas. Indica la fiabilidad del modelo al predecir la clase asociada al valor $y_i = 1$:

$$\text{Precisión} = \frac{TP}{TP + FP}$$

- **Sensibilidad (*Recall*)**: mide la proporción de positivos reales detectados por el modelo:

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

- **Especificidad (*Specificity*)**: mide la proporción de verdaderos negativos sobre el total de predicciones negativas:

$$\text{Especificidad} = \frac{TN}{TN + FP}$$

Además, generaremos curvas ROC (*Receiver Operating Characteristic*) a través del paquete `pROC` [12] para evaluar el poder predictivo del modelo en función de distintos umbrales de decisión (en el contexto de las SVM, el umbral varía sobre la distancia de los puntos a la frontera en lugar de utilizar probabilidades directas). Estas curvas ilustran la relación entre la sensibilidad y la tasa de falsos positivos. Para resumir el rendimiento del modelo en una única métrica, calcularemos el Área Bajo la Curva (AUC), donde se toma como referencia un valor de 0.5 perteneciente a un clasificador aleatorio. A medida que esta cantidad aumenta, la capacidad de discriminación del modelo es mayor, valiendo 1 en el modelo que separa perfectamente las clases [6].

Es importante mencionar que este análisis está diseñado para evaluar umbrales en problemas de clasificación binaria [12]. Dado que en casos multiclase las SVM construyen las fronteras de decisión bajo estrategias como *Uno-contra-Uno* [6] (comentadas en la Sección 2.6), no resulta viable representar una única curva ROC global. Por ello, para el caso práctico de la Sección 3.3, donde nuestra variable objetivo presenta $K > 2$ categorías, utilizaremos el promedio macro o *Macro-Averaging* de métricas en lugar del AUC [14]. Esta técnica consiste en calcular las métricas de forma individual para cada una de las K clases y posteriormente obtener su media aritmética sin ponderar. De esta forma, la importancia de un error en la clasificación es la misma para todas las clases.

En problemas de regresión

Dado que la función de coste de la SVR evalúa distancias a las fronteras del tubo ε , utilizaremos métricas que cuantifiquen la magnitud de dichas desviaciones de forma cuadrática y lineal:

- **Raíz del Error Cuadrático Medio (RMSE)**: eleva los errores al cuadrado para que siempre sean positivos y penalice más a los errores grandes, y posteriormente toma su raíz cuadrada de su promedio con el fin de obtener el error en la escala original:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (t_i - f(\mathbf{x}_i))^2}$$

- **Coefficiente de determinación (R^2)**: determina la proporción de varianza de la variable respuesta que es explicada por nuestro modelo:

$$R^2 = 1 - \frac{\sum_{i=1}^n (t_i - f(\mathbf{x}_i))^2}{\sum_{i=1}^n (t_i - \bar{t})^2},$$

siendo $\bar{t}$ la media de las t_i ($i = 1, \dots, n$). Su valor óptimo es 1, lo que indicaría que el ajuste es perfecto con un error de predicción nulo.

- **Error Absoluto Medio (MAE)**: mide el promedio de los errores de forma lineal mediante el valor absoluto. Así, los valores atípicos no son penalizados en exceso:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |t_i - f(\mathbf{x}_i)|$$

3.1.3. Herramientas de software

Para la ejecución práctica de los modelos, emplearemos el programa R. En concreto, haremos uso de la librería `e1071`, la cual está basada en la librería LIBSVM [3].

La función principal que utilizaremos para el entrenamiento es `svm()`. A nivel de programación, esta función requiere especificar algunos argumentos como el tipo de kernel que escojamos (`kernel`, permitiendo elegir entre lineales, polinómicos o radiales), la estandarización de las variables (`scale = TRUE`, activado por defecto) y la conservación de las distancias geométricas al hiperplano para poder trazar las curvas ROC (`decision.values = TRUE`).

Por otro lado, dado que el rendimiento de las SVM depende en gran medida de una adecuada selección de sus parámetros, no utilizaremos los valores por defecto. En su lugar, nos serviremos de la función `tune()`, la cual realiza una búsqueda en rejilla para encontrar la combinación óptima mediante la validación cruzada de 10 particiones descrita en la metodología. En concreto, esta función selecciona los hiperparámetros que minimizan el error promedio de clasificación (o MSE para regresión) sobre las 10 iteraciones, además de devolver su desviación típica para que el modelo final sea estable, de manera que escogeremos la configuración que minimice el error salvo donde se indique lo contrario. Fijamos una semilla inicial en todos los casos para obtener siempre los mismos resultados.

Los hiperparámetros que optimizaremos en nuestros experimentos son:

- **Parámetro de coste (C):** se encarga de lograr un margen amplio y minimizar los errores de clasificación simultáneamente. Como ya comentamos en la Sección 2.3.1, un valor bajo de C permite márgenes más suaves con más violaciones (mayor sesgo, menor varianza), mientras que un valor alto penaliza fuertemente los errores, buscando un hiperplano más ajustado a los datos (menor sesgo, mayor riesgo de *overfitting*). Este hiperparámetro estará presente en todos los modelos y se evaluará en el rango $[10^{-2}, 10^2]$.
- **Parámetro γ (*gamma*):** este parámetro es propio del kernel radial. Define la influencia que tiene un único individuo en la construcción de la frontera. Valores altos de γ implican un pequeño radio de influencia, generando fronteras de decisión complejas e irregulares. Concretamente, nuestra búsqueda de γ abarcará valores entre 10^{-4} y 10^1 .
- **Grado (d):** exclusivo del kernel polinómico, determina el grado del polinomio utilizado para proyectar los datos a un espacio de mayor dimensión. Al igual que el

hiperparámetro γ , su función está detallada en la Sección 2.4.1 Estudiaremos modelos polinómicos con grados $d = 2, 3, 4$.

- **Margen de tolerancia (ε):** este parámetro se utiliza en los problemas de regresión (SVR). Como vimos en la Sección 2.7, controla la anchura del tubo dentro del cual no se penalizan los errores de predicción, y tomará los valores $\varepsilon \in \{0.01, 0.05, 0.1, 0.5, 1\}$.

La generación de las distintas representaciones gráficas expuestas a lo largo de este trabajo se ha llevado a cabo mediante el paquete `ggplot2` [17].

Debido a la alta dimensionalidad de las variables predictoras en los conjuntos de datos analizados, resulta geoméricamente inviable visualizar las fronteras de decisión de los casos I y II mediante gráficos en dos dimensiones. Habría que fijar el resto de variables en valores constantes, de forma que no quedaría reflejado el verdadero comportamiento de los algoritmos. Por lo tanto, abordaremos el estudio de las SVM para clasificación desde una perspectiva cuantitativa, priorizando el uso de métricas de rendimiento sobre la representación visual.

Con la base metodológica, las métricas de evaluación y el software a emplear definidos, en las siguientes secciones aplicaremos estos algoritmos sobre distintos conjuntos de datos reales que detallaremos a continuación.

3.2. Caso Práctico I: Clasificación binaria

Nuestra primera aplicación práctica de las SVM tiene como objetivo clasificar los datos en dos categorías o clases distintas. El conjunto de datos escogido es *Breast Cancer Wisconsin (Diagnosis)*, el cual contiene un total de 569 individuos con 30 variables distintas que recopilan información sobre las células de una masa mamaria con la finalidad de detectar cáncer de pecho [18].

Específicamente, se analizaron los núcleos de las células y se midieron 10 características distintas, recopiladas en la Tabla 1:

Cada observación del conjunto de datos corresponde a una imagen microscópica del tejido de la paciente. El conjunto de datos resume las propiedades de las múltiples células presentes en una misma imagen a partir de tres métricas por cada una de las diez características base: la media, el error estándar y el valor del “peor caso” (calculado como la media de los tres valores más altos de la imagen, vitales para la detección de tumores).

Variable	Descripción
Radio (<i>radius</i>)	Media de las distancias desde el centro al perímetro
Textura (<i>texture</i>)	Desviación estándar de los valores en escala de grises
Perímetro (<i>perimeter</i>)	Perímetro del núcleo
Área (<i>area</i>)	Área del núcleo
Suavidad (<i>smoothness</i>)	Variación local en las longitudes de los radios
Compacidad (<i>compactness</i>)	$(\text{Perímetro}^2 / \text{Área}) - 1$
Concavidad (<i>concavity</i>)	Severidad de las porciones cóncavas del contorno
Puntos cóncavos (<i>concave points</i>)	Número de porciones cóncavas del contorno
Simetría (<i>symmetry</i>)	Simetría del núcleo celular
Dimensión fractal (<i>fractal dimension</i>)	Aproximación de la frontera -1

Tabla 1: Descripción de las variables del dataset *Breast Cancer Wisconsin (Diagnosis)*.

Esto genera un espacio de características final de 30 variables predictoras. Todas ellas se encargarán de predecir si la variable objetivo *Diagnosis* es *B* (núcleo benigno, 357 individuos) o *M* (núcleo maligno, 212 individuos).

A continuación, vamos a entrenar tres modelos, uno por cada tipo de kernel visto en la Sección 2.4.1. El código utilizado para seleccionar los hiperparámetros está incluido en el Anexo A.1.

La siguiente tabla muestra los modelos obtenidos:

Tipo de kernel	Hiperparámetros seleccionados	% de vectores de soporte
Lineal	$C = 1$	7.02 %
Polinómico	$C = 1, d = 2$	13.53 %
Radial	$C = 10, \gamma = 0.01$	12.28 %

Tabla 2: Configuraciones óptimas y porcentaje de vectores de soporte obtenidos para cada tipo de kernel sobre el conjunto de entrenamiento.

Como se puede apreciar en la Tabla 2, las configuraciones óptimas seleccionadas mediante validación cruzada mantienen un bajo porcentaje de vectores de soporte. Este hecho es un indicio de que los tres modelos han logrado definir sus fronteras de decisión sin memorizar los datos.

Una vez planteados los 3 modelos, determinemos cuál brinda una mejor actuación sobre el conjunto test a partir de sus curvas ROC, como puede observarse en la Figura 11:




Figura 11: Comparación de las curvas ROC y valores AUC para los modelos lineal, polinómico y radial sobre el conjunto de test.

Las tres curvas ROC obtenidas esclarecen la gran capacidad predictiva de los modelos, pues todas tienen un valor AUC muy cercano a 1. Para analizar este rendimiento en detalle, la Tabla 3 resume las métricas globales obtenidas sobre el conjunto de test:

Modelo	Precisión	Sensibilidad	Especificidad	AUC
Lineal	1.0000	0.9048	1.0000	0.9852
Polinómico	0.9677	0.9524	0.9813	0.9967
Radial	0.9833	0.9365	0.9907	0.9961

Tabla 3: Métricas de rendimiento de los modelos SVM sobre el conjunto de test.

A la vista de estos resultados, el kernel polinómico despunta con el mayor Área Bajo la Curva ($AUC = 0.9967$). Aunque el kernel radial presenta un rendimiento extremadamente próximo ($AUC = 0.9961$), su matriz de confusión revela que detecta un tumor maligno menos que el kernel polinómico, disminuyendo su sensibilidad (véase el Anexo A.1 para consultar la matriz de confusión detallada de los modelos descartados). Por consiguiente, seleccionamos el modelo SVM de kernel polinómico como el clasificador definitivo para este conjunto de datos.

Para ilustrar el comportamiento final del clasificador seleccionado, la Tabla 4 muestra la matriz de confusión generada por el modelo SVM polinómico sobre los 170 individuos que componen el conjunto de test:

		Realidad	
		<i>Benigno (B)</i>	<i>Maligno (M)</i>
Predicción	<i>Benigno (B)</i>	105	3
	<i>Maligno (M)</i>	2	60

Tabla 4: Matriz de confusión de la SVM polinómica sobre el conjunto test.

Esta matriz expone de forma clara la fiabilidad del modelo polinómico, ya que logra diagnosticar correctamente la gran mayoría de los tumores malignos mientras mantiene al mínimo las falsas alarmas, cumpliendo así con las altas exigencias de este tipo de problemas médicos.

3.3. Caso Práctico II: Clasificación multiclase

Para el segundo caso de aplicación práctica de las SVM, la variable objetivo de nuestro conjunto de datos presenta más de dos categorías diferentes. Los datos provienen de *Vehicle Silhouettes*, que registra 846 entradas relativas a siluetas de vehículos con el propósito de identificar un autobús de dos plantas (*bus*, 218), una furgoneta Chevrolet (*van*, 199), un Saab 9000 (*saab*, 217) o un Opel Manta 400 (*opel*, 212) [10]. Para ello, disponemos de 18 variables que miden distintas métricas de las siluetas, las cuales se detallan en la Tabla 11 del Anexo A.2.

De nuevo, entrenamos modelos con kernels lineal, polinómico y radial, respectivamente. Sus hiperparámetros y porcentaje de vectores de soporte se muestran en la Tabla 5:

Tipo de kernel	Hiperparámetros seleccionados	% de vectores de soporte
Lineal	$C = 10$	44.61 %
Polinómico	$C = 10, d = 2$	47.64 %
Radial	$C = 100, \gamma = 0.01$	48.99 %

Tabla 5: Configuraciones óptimas y porcentaje de vectores de soporte obtenidos para cada tipo de kernel sobre el conjunto de entrenamiento.

Como observamos en la tabla, el porcentaje de vectores de soporte de los modelos es mucho mayor que en el caso anterior, acercándose al 50 % del conjunto de entrenamiento

para todos los kernels. Sin embargo, este suceso no termina siendo tan sorprendente si prestamos atención al tipo de problema planteado: al existir 4 categorías con cierto solapamiento (especialmente entre los turismos Saab y Opel), cada modelo necesitará una gran cantidad de vectores de soporte para definir unas fronteras de decisión adecuadas en un espacio de 18 dimensiones.

Dado que las categorías de este conjunto de datos mantienen una proporción de individuos similar, resulta provechoso emplear la exactitud como métrica principal en este contexto. Por ello, la siguiente tabla incluye esta métrica en lugar del AUC, cuyo análisis posee mayor complejidad cuando la clasificación no es binaria:

Modelo	Exactitud	Precisión	Sensibilidad	Especificidad
Lineal	0.8532	0.8581	0.8546	0.9509
Polinómico	0.8135	0.8094	0.8163	0.9377
Radial	0.8135	0.8101	0.8150	0.9377

Tabla 6: Métricas de rendimiento de los modelos SVM sobre el conjunto de test.

La Tabla 6 muestra que aumentar la complejidad de un modelo no siempre se traduce en un éxito mayor, pues el modelo lineal es el que presenta las mejores métricas. Por lo tanto, es el clasificador que seleccionamos en este caso práctico.

A continuación se muestra la matriz de confusión del modelo lineal sobre las 252 siluetas que conforman el conjunto test:

		Realidad			
		<i>bus</i>	<i>opel</i>	<i>saab</i>	<i>van</i>
Predicción	<i>bus</i>	63	0	1	0
	<i>opel</i>	1	38	7	0
	<i>saab</i>	0	22	55	0
	<i>van</i>	1	3	2	59

Tabla 7: Matriz de confusión de la SVM lineal sobre el conjunto test.

A partir de la Tabla 7 podemos obtener varias conclusiones sobre el comportamiento del modelo. Por un lado, observamos la alta precisión a la hora de detectar vehículos con formas características, ya que acierta con 63 de los 65 autobuses reales y la totalidad de las 59 furgonetas. Sin embargo, tal y como preveíamos, el modelo sufre tratando de diferenciar los turismos, pues etiqueta como Saab una tercera parte de los Opel. Aunque

este error reduce el rendimiento general, el resto de matrices de confusión del Anexo A.2 muestran que los modelos no lineales presentan menores tasas de acierto.

3.4. Caso Práctico III: Regresión

La última aplicación práctica de las SVM que vamos a estudiar en esta memoria toma el conjunto de datos *Abalone*, que contiene información sobre 4177 abulones recogidos en 8 variables distintas [11]. La diferencia de este caso práctico con respecto a los anteriores es que en esta ocasión la variable a predecir es la edad de dichos moluscos, por lo que no se trata de un problema de clasificación sino de regresión.

La edad de un abulón se obtiene sumando 1.5 años al número de anillos de su concha, motivo por el cual los modelos toman *Rings* como variable objetivo. A continuación, la Tabla 8 resume la información extraída:

Variable	Descripción
Sexo (<i>Sex</i>)	M (macho), F (hembra) e I (cría)
Longitud (<i>Length</i>)	Medida del eje más largo de la concha (mm)
Diámetro (<i>Diameter</i>)	Perpendicular a la longitud principal (mm)
Altura (<i>Height</i>)	Altura con el molusco en la concha (mm)
Peso total (<i>Whole_weight</i>)	Masa íntegra del abulón (gramos)
Peso sin concha (<i>Shucked_weight</i>)	Tejido blando extraído del caparazón (gramos)
Peso de las vísceras (<i>Viscera_weight</i>)	Intestinos tras el sangrado (gramos)
Peso de la concha (<i>Shell_weight</i>)	Estructura calcárea tras ser secada (gramos)
Anillos (<i>Rings</i>)	Número de anillos (+1.5 indica la edad en años)

Tabla 8: Descripción de las variables del dataset *Abalone*.

Aunque las SVM necesitan variables numéricas para su correcto desarrollo, notamos que este conjunto de datos presenta una variable predictora categórica (*Sex*). Para solventar este problema, la función `svm()` convierte las categóricas en variables indicadoras binarias, tal y como se detalla en [3].

Como podemos observar en la Figura 12, la variable objetivo tiene una distribución asimétrica. La gran mayoría de los individuos se concentra en el rango de 5 a 14 anillos, disminuyendo rápidamente la información disponible de abulones con 15 o más anillos.

Los modelos entrenados de SVR se encuentran en la Tabla 9. Con el objetivo de reducir el coste computacional de ejecutar una búsqueda en rejilla con tres hiperparámetros tras




Figura 12: Histograma de la variable *Rings* del conjunto de datos *Abalone*.

incluir el margen de tolerancia ε en la función `tune()`, hemos limitado el rango de C y γ a $\{10^{-1}, \dots, 10^2\}$ y $\{10^{-3}, \dots, 10^0\}$, respectivamente. Para mayor detalle, una lista con las 5 mejores configuraciones está presente en el Anexo A.3.

Tipo de kernel	Hiperparámetros seleccionados	% de vectores de soporte
Lineal	$C = 10$, $\varepsilon = 0.5$	35.52 %
Polinómico	$C = 10$, $d = 2$, $\varepsilon = 0.5$	33.30 %
Radial	$C = 10$, $\gamma = 0.1$, $\varepsilon = 0.5$	33.37 %

Tabla 9: Configuraciones óptimas y porcentaje de vectores de soporte obtenidos para cada tipo de kernel sobre el conjunto de entrenamiento.

Es fácil de ver que los tres modelos seleccionados poseen el mismo coste C y la misma anchura del tubo pese a utilizar distintos kernels. Las proporciones de vectores de soporte empleados también son similares entre sí y algo inferiores a las obtenidas en el caso multiclase. Este hecho sugiere que, en nuestro estudio, las SVM (SVR, en esta ocasión) funcionan de manera más eficiente en problemas de regresión que en problemas de clasificación con varias categorías. Para decidir el mejor modelo, mostramos las métricas obtenidas sobre el test en la Tabla 10:

La mencionada tabla nos explica que los modelos con kernel lineal y polinómico cometen distintos tipos de errores: el RMSE es menor en el modelo lineal mientras que el MAE es menor en el modelo polinómico. El posible motivo de este suceso es que el modelo

Modelo	RMSE	R^2	MAE
Lineal	2.3114	0.5147	1.6052
Polinómico	2.3602	0.4941	1.5354
Radial	2.1556	0.5780	1.5017

Tabla 10: Métricas de rendimiento de los modelos SVR sobre el conjunto de test.

polinómico es más preciso pero sus errores son más graves, siendo el modelo lineal más estable por no tener tanto error cuadrático aunque se penalice con un aumento en su error absoluto medio.

Sin embargo, ninguno de los dos se aproxima al radial, el cual es el más competente en todas las métricas: su error promedio es de 1.5 anillos por predicción y logra explicar un 57.8% de la varianza total de los datos. Pero es su reducción del RMSE a 2.1556 lo que lo convierte en el mejor modelo, ya que esta métrica castiga duramente las desviaciones atípicas. En el contexto biológico del abulón, un RMSE bajo garantiza la ausencia de predicciones graves, asegurando una generalización mucho más fiable.




Figura 13: Gráfica del modelo de SVR con kernel radial sobre el conjunto de test. Los puntos azules muestran los individuos estudiados, mientras que la línea roja discontinua sitúa la ubicación ideal de los abulones, donde el número real de anillos coincidiría con los valores predichos.

Como se ilustra en la Figura 13, la gráfica de la realidad frente a la predicción del modelo confirma el buen rendimiento de la SVR radial. En la zona central, las predicciones rodean la línea ideal, demostrando que el modelo ha capturado la relación para la mayoría de la población.

Sin embargo, la escasez de muestras en los extremos vista en el histograma de la Figura 12 provoca dos claros sesgos. Por un lado, el modelo otorga más edad a los individuos jóvenes al ubicar las predicciones de menor cantidad de anillos por encima de la diagonal, al mismo tiempo que los abulones más longevos reciben predicciones muy por debajo de su número real de anillos debido a la falta de entrenamiento en esa etapa vital.

4. Conclusiones

El desarrollo de este Trabajo de Fin de Grado ha permitido realizar una exploración detallada del funcionamiento de las Máquinas de Vectores de Soporte (SVM), logrando comprender el algoritmo desde su base teórica hasta sus aplicaciones prácticas.

Desde un punto de vista analítico, este estudio ha mostrado el cambio de perspectiva que otorgaron las SVM en comparación con las técnicas de estadística tradicionales. Mientras que los algoritmos clásicos optimizaban en base a minimizar el error cuadrático medio, las SVM buscan maximizar el margen de separación empleando funciones de coste como la *hinge loss* en clasificación o la ε -insensibilidad en regresión. De este modo, es posible trazar fronteras de decisión mucho más resistentes frente a valores atípicos.

Asimismo, el trabajo ha indagado con éxito en la versatilidad de este modelo. Se ha detallado cómo el *truco del kernel* concede al algoritmo la capacidad de resolver problemas no lineales sin un excesivo aumento del coste computacional. Además, se ha comprobado la potencia de las SVM para ir más allá de la clasificación binaria, su objetivo original, adaptándose a escenarios como la clasificación multiclase y reformulando su base geométrica mediante el tubo de tolerancia (ε) para predecir variables continuas a través de la Regresión de Vectores de Soporte (SVR).

En la práctica, la implementación de estos modelos sobre diferentes conjuntos de datos ha revelado el verdadero potencial de las SVM. En primer lugar, destaca su eficiencia: el algoritmo es capaz de construir fronteras de decisión complejas utilizando una fracción de los datos de entrenamiento (abarcando desde el 7 % hasta el 49 % como vectores de soporte en los casos estudiados). Por otro lado, los resultados obtenidos en la detección de tumores mamarios han mostrado que el tipo de kernel permite adaptar el modelo al contexto del problema; al seleccionar un kernel polinómico de grado bajo, se sacrificó una pequeña mejora en la precisión global para maximizar la sensibilidad en el conjunto de test, priorizando minimizar los falsos negativos en un entorno clínico. Además, el caso de *Vehicle Silhouettes* demostró que aumentar la complejidad matemática no siempre es la respuesta óptima, pues la frontera lineal fue la más acertada al clasificar los individuos.

Sin embargo, el análisis de los resultados también exige un ejercicio de autocrítica respecto a las limitaciones de este modelo. En problemas de regresión con variabilidad biológica, como el caso de *Abalone*, el modelo radial alcanzó un coeficiente de determinación máximo de $R^2 \approx 0.58$. Aunque a primera vista parezca un fracaso del algoritmo, este resultado expone que las SVM, por potentes que sean aislando patrones, no pueden hacer frente a los límites del ruido de los datos.

A nivel técnico, es necesario mencionar que la búsqueda de hiperparámetros mediante validación cruzada conlleva un coste computacional considerable cuando se aplica sobre conjuntos de datos extensos, y que el hiperplano óptimo del modelo en ocasiones carece de interpretación directa.

Referencias

- [1] Bishop, C.M. (2006) *Pattern Recognition and Machine Learning*. Springer.
- [2] Boser, B.E., Guyon, I.M., and Vapnik, V.N. (1992). *A training algorithm for optimal margin classifiers* in *Proceedings of the fifth annual workshop on Computational learning theory*, 144-152. <https://doi.org/10.1145/130385.130401>
- [3] Chang, C.-C. and Lin, C.-J. (2011). LIBSVM: A library for support vector machines. *ACM Transactions on Intelligent Systems and Technology (TIST)*, **2**(3), 1-27. <https://doi.org/10.1145/1961189.1961199>
- [4] Cortes, C. and Vapnik, V.N. (1995). *Support-vector networks*. *Machine learning* **20**, 273-297. <https://doi.org/10.1007/BF00994018>
- [5] Hastie, T., Tibshirani, R. and Friedman, J. (2009) *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- [6] James, G., Witten, D., Hastie, T. and Tibshirani, R. (2013) *An Introduction to Statistical Learning: With Applications in R*. Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- [7] Karatzoglou, A., Meyer, D. and Hornik, K. (2006). *Support Vector Machines in R*. *Journal of Statistical Software* **15**, 1-28. <https://doi.org/10.18637/jss.v015.i09>
- [8] Kuhn, M. (2008). *Building Predictive Models in R Using the caret Package*. *Journal of Statistical Software* **28**(5), 1-26. <https://doi.org/10.18637/jss.v028.i05>
- [9] Meyer, D., Dimitriadou, E., Hornik, K., Weingessel, A. and Leisch, F. (2025). *e1071: Misc Functions of the Department of Statistics, Probability Theory Group (Formerly: E1071), TU Wien*. R package version 1.7-17. <https://CRAN.R-project.org/package=e1071> (Consultado el 29 de abril de 2026).

- [10] Mowforth, P. and Shepherd, B. Statlog (Vehicle Silhouettes) [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5HG6N> (Consultado el 2 de mayo de 2026).
- [11] Nash, W., Sellers, T., Talbot, S., Cawthorn, A., and Ford, W. (1994). Abalone [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C55C7W> (Consultado el 2 de mayo de 2026).
- [12] Robin, X., Turck, N., Hainard, A., Tiberti, N., Lisacek, F., Sanchez, J.C. and Müller, M. (2011). *pROC: an open-source package for R and S+ to analyze and compare ROC curves*. *BMC Bioinformatics* **12**, 77. <https://doi.org/10.1186/1471-2105-12-77>
- [13] Smola, A.J. and Schölkopf, B. (2004). *A tutorial on support vector regression*. *Statistics and Computing* **14**, 199-222. <https://doi.org/10.1023/B:STCO.0000035301.49549.88>
- [14] Sokolova, M. and Lapalme, G. (2009). *A systematic analysis of performance measures for classification tasks*. *Information Processing and Management* **45** (4), 427-437. <https://doi.org/10.1016/j.ipm.2009.03.002>.
- [15] Vapnik, V. N. and Chervonenkis, A. Y. (1964). *A note on one class of perceptrons*. *Automation and Remote Control* **25**, 112-120.
- [16] Vapnik, V.N., The Support Vector Method for Estimating Indicator Functions in *Statistical Learning Theory*, Vapnik, V.N. (1998) pp.401-442.
- [17] Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. <https://doi.org/10.1007/978-3-319-24277-4>
- [18] Wolberg, W., Mangasarian, O., Street, N., and Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5DW2B> (Consultado el 2 de mayo de 2026).

A. Código utilizado en R y Resultados Complementarios

Todo el código utilizado para la carga de datos, el entrenamiento de los modelos y la generación de las gráficas teóricas de esta memoria se encuentra documentado y disponible de forma abierta en el siguiente repositorio de GitHub:

<https://github.com/DanSanchezB/TFG-SVM>

Para completar los análisis de los modelos sobre cada conjunto de datos, a lo largo de este Anexo se detallan los resultados de las 5 configuraciones con menor error en la validación cruzada de los modelos, así como las matrices de confusión de los modelos de clasificación descartados y las gráficas de predicción de aquellos desestimados en la regresión.

Las salidas de las métricas de rendimiento vienen dadas a partir de funciones personalizadas, las cuales se encuentran disponibles dentro del script de R del repositorio indicado.

A.1. Caso Práctico I: Clasificación Binaria

Modelo con Kernel Lineal (Descartado)

Resultado de la validación cruzada para la búsqueda del coste óptimo:

TOP 5 MODELOS (KERNEL LINEAL):

	cost	error	dispersion
3	1e+00	0.02506410	0.02357110
1	1e-02	0.02506410	0.02041342
2	1e-01	0.03006410	0.01579015
4	1e+01	0.03250000	0.03545341
5	1e+02	0.05262821	0.04321467

Matriz de confusión sobre el conjunto de test:

MATRIZ DE CONFUSIÓN:

	Reference	
Prediction	B	M
B	107	6
M	0	57

Modelo con Kernel Polinómico (Ganador)

Dado que la matriz de confusión de este modelo ya se ha expuesto y analizado en la Sección 3.2, aquí se incluyen únicamente los resultados de la validación cruzada utilizada para seleccionar sus hiperparámetros óptimos:

TOP 5 MODELOS (KERNEL POLINÓMICO):

	cost	degree	error	dispersion
13	1.0	4	0.01500000	0.01748015
3	1.0	2	0.02000000	0.02297341
4	10.0	2	0.02000000	0.02297341
8	1.0	3	0.02000000	0.02297341
12	0.1	4	0.02512821	0.02059013

Como se refleja en los resultados de la validación cruzada para el kernel polinómico, la configuración óptima se alcanza con un coste de $C = 1$ y un polinomio de grado $d = 4$. Sin embargo, hemos escogido la configuración $C = 1, d = 2$ dado que la mejora del error aportada por el grado 4 es de apenas un 0.5% y emplear un polinomio con un grado tan alto generará fronteras de decisión muy complejas que podrían memorizar los datos en lugar de aprender de ellos.

Modelo con Kernel Radial (Descartado)

Resultado de la validación cruzada para la búsqueda del coste y grado óptimos:

TOP 5 MODELOS (KERNEL RADIAL):

	cost	gamma	error	dispersion
14	10	1e-02	0.0175000	0.02058182
10	100	1e-03	0.0225000	0.02188988
13	1	1e-02	0.0225641	0.01845738
5	100	1e-04	0.0250641	0.01666790
9	10	1e-03	0.0250641	0.01666790

Matriz de confusión sobre el conjunto de test:

MATRIZ DE CONFUSIÓN:

	Reference	
Prediction	B	M
B	106	4
M	1	59

A.2. Caso Práctico II: Clasificación Multiclase

El conjunto de datos *Vehicle Silhouettes* posee 18 variables explicativas, las cuales detallamos a continuación:

Variable	Descripción
Compacidad (<i>compactness</i>)	$(\text{perímetro medio})^2 / \text{área}$
Circularidad (<i>circularity</i>)	$(\text{radio medio})^2 / \text{área}$
Circularidad de distancia (<i>distance circularity</i>)	$\text{área} / (\text{distancia media al borde})^2$
Razón de radios (<i>radius ratio</i>)	$(\text{radio máximo} - \text{radio mínimo}) / \text{radio medio}$
Razón de aspecto del eje principal (<i>pr.axis aspect ratio</i>)	eje menor / eje mayor
Razón de aspecto de la longitud máxima (<i>max.length aspect ratio</i>)	longitud perpendicular a la máxima / longitud máxima
Razón de dispersión (<i>scatter ratio</i>)	inercia eje menor / inercia eje mayor
Elongación (<i>elongatedness</i>)	$\text{área} / (\text{ancho contraído})^2$
Rectangularidad del eje principal (<i>pr.axis rectangularity</i>)	$\text{área} / (\text{longitud eje principal} \times \text{ancho eje principal})$
Rectangularidad de la longitud máxima (<i>max.length rectangularity</i>)	$\text{área} / (\text{longitud máxima} \times \text{longitud perpendicular a la máxima})$
Varianza escalada respecto al eje mayor (<i>scaled variance major</i>)	momento de 2º orden eje menor / área
Varianza escalada respecto al eje menor (<i>scaled variance minor</i>)	momento de 2º orden eje mayor / área
Radio de giro escalado (<i>scaled radius of gyration</i>)	$(\sigma_{\text{maj}}^2 + \sigma_{\text{min}}^2) / \text{área}$
Asimetría respecto al eje mayor (<i>skewness about major axis</i>)	momento de tercer orden eje mayor / σ_{min}^3
Asimetría respecto al eje menor	momento de tercer orden eje menor / σ_{maj}^3

(<i>skewness about minor axis</i>)	
Curtosis respecto al eje menor (<i>kurtosis about minor axis</i>)	momento de 4º orden eje mayor/ $\sigma_{\min}^4$
Curtosis respecto al eje mayor (<i>kurtosis about major axis</i>)	momento de 4º orden eje menor/ $\sigma_{\max}^4$
Índice de concavidad (<i>hollows ratio</i>)	área de huecos/área del polígono envolvente

Tabla 11: Descripción de las variables predictoras del conjunto de datos *Vehicle Silhouettes*.

Modelo con Kernel Lineal (Ganador)

La matriz de confusión de este modelo se encuentra en la Sección 3.3. Es por eso que aquí se incluye únicamente la selección del coste óptimo mediante validación cruzada:

TOP 5 MODELOS (KERNEL LINEAL):

	cost	error	dispersion
4	1e+01	0.2186723	0.06087124
3	1e+00	0.2322034	0.06606909
5	1e+02	0.2371186	0.06282024
2	1e-01	0.2609040	0.05961444
1	1e-02	0.3501412	0.07431356

Modelo con Kernel Polinómico (Descartado)

Resultado de la validación cruzada para la búsqueda del coste y grado óptimos:

TOP 5 MODELOS (KERNEL POLINÓMICO):

	cost	degree	error	dispersion
4	10	2	0.1616949	0.04163752
5	100	2	0.1634463	0.05553292
10	100	3	0.1885876	0.07206832
9	10	3	0.1919209	0.05848969
15	100	4	0.1919209	0.06070288

Matriz de confusión sobre el conjunto de test:

MATRIZ DE CONFUSIÓN:

		Reference			
Prediction		bus	opel	saab	van
	bus	64	0	1	1
	opel	1	42	20	0

saab	0	18	41	0
van	0	3	3	58

Modelo con Kernel Radial (Descartado)

Resultado de la validación cruzada para la búsqueda del coste y parámetro γ óptimos:

TOP 5 MODELOS (KERNEL RADIAL):

	cost	gamma	error	dispersion
15	100	0.010	0.1731073	0.06036065
20	100	0.100	0.2135593	0.07373789
14	10	0.010	0.2152825	0.06728522
10	100	0.001	0.2203955	0.06089779
19	10	0.100	0.2237006	0.07079658

Matriz de confusión sobre el conjunto de test:

MATRIZ DE CONFUSIÓN:

		Reference			
Prediction		bus	opel	saab	van
bus	65	0	1	4	
opel	0	44	19	1	
saab	0	16	42	0	
van	0	3	3	54	

A.3. Caso Práctico III: Regresión

Modelo con Kernel Lineal (Descartado)

Resultado de la validación cruzada para la búsqueda del coste y margen de tolerancia óptimos:

TOP 5 MODELOS (KERNEL LINEAL):

	cost	epsilon	error	dispersion
16	100.0	0.5	4.746051	0.5459704
15	10.0	0.5	4.749053	0.5449244
14	1.0	0.5	4.752738	0.5397104
13	0.1	0.5	4.800650	0.5347592
12	100.0	0.1	4.876178	0.5905626

Como observamos en los resultados de la lista, la configuración óptima devuelta por la validación cruzada toma el coste $C = 100$. No obstante, en la memoria principal hemos utilizado el modelo con $C = 10$. Dada la minúscula diferencia de 0.003 en sus errores,

optamos por escoger un modelo más simple para disminuir el riesgo de sobreajuste y favorecer la generalización del modelo.




Figura 14: Gráfica del modelo de SVR con kernel lineal sobre el conjunto de test de Abalone.

La Figura 14 muestra cómo la rigidez del modelo lineal impide un correcto ajuste a los datos, elevando significativamente los errores en los extremos de la muestra.

Modelo con Kernel Polinómico (Descartado)

Resultado de la validación cruzada para la búsqueda del coste, grado y margen de tolerancia óptimos:

TOP 5 MODELOS (KERNEL POLINÓMICO):

	cost	degree	epsilon	error	dispersion
39	10	2	0.50	4.460073	0.6506921
38	1	2	0.50	4.489894	0.5998380
3	10	2	0.01	4.504584	0.6621566
15	10	2	0.05	4.507383	0.6746424
4	100	2	0.01	4.516974	0.6809092

La Figura 15 expone que el modelo polinómico presenta una tendencia similar al radial (recogido en la Figura 13), ya que predice adecuadamente los individuos de la zona central pero subestima los abulones con muchos anillos.




Figura 15: Gráfica del modelo de SVR con kernel polinómico sobre el conjunto de test de *Abalone*.

Modelo con Kernel Radial (Ganador)

Dado que la gráfica de este modelo ya se ha expuesto y analizado en la Sección 3.4, aquí se incluye únicamente la información relativa a la validación cruzada utilizada para seleccionar sus hiperparámetros óptimos:

TOP 5 MODELOS (KERNEL RADIAL):

	cost	gamma	epsilon	error	dispersion
59	10	0.10	0.50	4.356152	0.5906917
56	100	0.01	0.50	4.397433	0.6031627
58	1	0.10	0.50	4.430281	0.5731691
43	10	0.10	0.10	4.456373	0.6126443
27	10	0.10	0.05	4.457352	0.6162468

B. Detalles del desarrollo del trabajo

Tarea	Tiempo (horas)
Recopilación de materiales	15
Estudio de bibliografía	25
Elaboración de resultados gráficos/numéricos	40
Redacción de la memoria	70
Total	150

Tabla 12: *Tiempo aproximado de dedicación al trabajo*

Asignatura	Páginas	Descripción
Geometría Lineal	8	Def. 2.1 está adaptada a partir de los apuntes
Análisis de Datos I	9	Def. 2.2 está basada en la definición de estos apuntes
Optimización II	18, 31	En esta asignatura se impartió la técnica para la correcta aplicación de las condiciones de holgura complementaria.
Análisis de Datos II	34-36	La metodología de la Sección 3 aplica los conocimientos adquiridos en esta asignatura.

Tabla 13: *Asignaturas relacionadas con el trabajo*